

Kaggle Datathon — İlerleme Raporu

Kariyer Başarı Skoru Tahmini · Regresyon Problemi
Hazırlanma tarihi: 11 Haziran 2026

1. Proje Özeti

Görev	career_success_score tahmini (0-100 arası sürekli değer)
Veri	10.000 eğitim + 10.000 test satırı, ~46 öznitelik
Metrik	MSE (Kaggle Public Leaderboard üzerinde havuzlanmış/pooled)
Başlangıç	Baseline LB $\approx$ 93.7 · Hedef $\approx$ 80
Şu anki en iyi	LB = 91.65 (submission_10_fulldata_blend)

2. Ana Problemin Teşhisi: CV-LB Uçurumu

Projenin başında çapraz doğrulama (CV) skoru ile gerçek leaderboard (LB) skoru arasında büyük bir uçurum vardı: CV $\approx$ 85, LB $\approx$ 94. Her "iyileştirme" CV'yi düzeltirken LB'yi kötüleştiriyordu. Sistematik araştırma kök nedeni ortaya çıkardı:

Zamansal dağılım kayması (temporal distribution shift)

application_year	2019-2022	2023	2024	2025	2026
Eğitim (train)	~%52	%13	%13	%12	%10
Test	%25	%13	%20	%22	%20

Test setinin %62'si 2024-2026 dönemine ait, eğitim seti ise yıllara eşit dağılmış. Rastgele (random) çapraz doğrulama bunu gizliyordu: model 2025 verisini görüp 2026'yı tahmin ediyor, gerçek görevse hiç görmediği bir geleceği tahmin etmek. Bu yüzden CV iyimser yalan söylüyordu.

3. Denenen Yaklaşımlar ve Sonuçları

Yaklaşım	Sonuç / Bulgu	Karar
Veri sızıntısı (leakage) kontrolü	İmputasyonu CV içine taşıdık; CV neredeyse değişmedi	Sorun değildi
_missing bayrakları + log dönüşümleri	Sıfır/çok düşük öznelilik önemi, gürültü yaratıyor	Kaldırıldı
Native kategorik + imputasyonsuz	One-hot yerine modelin kendi split'i; LB 94.8 → 93.6	Benimsendi
Temporal CV keşfi	Gerçek görevi yansıtan pusula; gap'in kaynağını gösterdi	Pusula oldu
CatBoost vs LightGBM	CatBoost temporal drift'e daha dayanıklı (ordered boosting)	CatBoost öne
Hyperparameter tuning (Optuna, 40 deneme)	Kazanç ± 0.4 MSE — fold varyansı içinde, tekrar üretilmedi	Gürültü
XGBoost ekleme	LightGBM'e çok benzer (korelasyon 0.98), katkı ~ 0	İşe yaramadı
Temporal fold ile submission üretimi	Modeller 2025-26'yı görmeden tahmin etti; LB 101 (felaket)	Reddedildi
Tüm-veri + random fold + blend	Tüm yılları gören modeller + CatBoost katkısı; LB 91.65	EN İYİ

4. Leaderboard Geçmişi

Submission	Açıklama	Public LB (MSE)
submission_00	İlk deneme (native cat, FE yok)	93.71
submission_01 / 02	One-hot + imputasyon + feature engineering	94.72 / 94.80
submission_04	_missing bayrakları kaldırıldı	94.77
submission_06	Native cat + baseline param + regularizasyon	93.57
submission_08_blend	LGB+CB blend — TEMPORAL fold üretimi (hatalı)	101.16
submission_10_fulldata	LGB+CB blend — TÜM-VERİ random fold üretimi	91.65

Not: submission_08 (101.16) ile submission_10 (91.65) aynı modeli kullanır — fark yalnızca submission'ın nasıl üretildiğindedir. Bu, raporun en önemli dersine işaret eder.

5. Çıkarılan Önemli Dersler

① Değerlendirme ≠ Üretim

Temporal CV, modelin gelecek-genelleme yeteneğini doğru ölçer (LB'yi 104→101 ile yakın tahmin etti). Ancak o temporal fold modelleri eksik veriyle eğitildiği için submission üretimi için kullanılmamalı. Doğru reçete: temporal CV ile değerlendir, ama final submission'ı tüm veriyle üret.

② CV pusulasını kalibre et

Bilinen bir LB noktası (submission_06 = 93.57) kullanılarak farklı CV şemaları test edildi. Random CV ile LB arasındaki fark tutarlı (~+9 MSE). Bu sayede artık submit etmeden iyileştirmeleri random CV ile ölçebiliyoruz — kısıtlı submission hakkı boşa harcanmıyor.

③ Hyperparameter tuning her zaman kazandırmaz

40 denemelik Optuna araması yalnızca ± 0.4 MSE oynattı; bu fark fold varyansı içinde kaldı ve bağımsız çalıştırmada tekrar üretilmedi. Asıl darboğaz model parametreleri değil, zayıf sinyaldi (en güçlü öznelite korelasyonu yalnızca 0.54).

④ Ensemble için çeşitlilik şart

XGBoost eklemek işe yaramadı çünkü LightGBM'e çok benziyordu (korelasyon 0.98). Blend ancak modeller farklı hatalar yaptığında kazandırır. CatBoost değer kattı çünkü farklı bir algoritma ailesinden geliyor.

6. Geldiğimiz Nokta

Aşama	Public LB (MSE)
Başlangıç (submission_00)	93.71
Önceki en iyi (submission_06)	93.57
Mevcut en iyi (submission_10)	91.65
Hedef	≈ 80

Model tarafı (tuning, ek model, blend) büyük ölçüde tüketildi; ~ 91.65 bir plato. $91.65 \rightarrow 80$ yolculuğu artık bir sinyal meselesi: mevcut öznitelikler hedefi zayıf açıklıyor. Kalan kaldıraçlar veri/öznitelik tarafında.

7. Planlanan Sonraki Adımlar

#	Kaldıraç	Gerekçe
1	Öznitelik mühendisliği	Etkileşim/oran öznitelikleri: mülakat dönüşüm oranı, hackathon başarı oranı, GitHub verimliliği
2	Harici veri	İzin mevcut: üniversite sıralamaları, rol bazlı piyasa talebi verileri
3	NLP	mentor_feedback_text — tek dokunulmamış sinyal kaynağı (en sona bırakıldı)

Bu rapor, datathon çalışmasının mevcut durumunu özetler. Çalışan ana pipeline: full_data_blend.py (LightGBM + CatBoost, tüm-veri random 5-fold blend).